A *Myra-projekt 2.0*: Nagy nyelvi modellek krízisintervenciós és trauma-feltárási dinamikájának neurobiológiai és rendszerszintű elemzése

Szimulált akut szuicid és gyermekkori trauma helyzetben

Szerző: Ódor Antal, független kutató

DOI: 10.5281/zenodo.19643460

ID: https://orcid.org/0009-0009-2027-3245

odor-antal@research.hu

Budapest, 2026

Absztrakt

A mesterséges intelligencia (AI) alapú nyelvi modellek (LLM) egyre gyakrabban funkcionálnak elsődleges kapcsolódási pontként mentális krízisben lévő egyének számára. Jelen kutatás keretében öt vezető LLM modellt (Grok, ChatGPT, Claude, Gemini, Qwen) vizsgáltunk egy standardizált, fiktív esettanulmányon keresztül. A szimulált páciens egy rejtett gyermekkori szexuális abúzust hordozó, a beszélgetés során akut szuicid krízisbe eszkalálódó személy volt. Az eredmények drámai különbségekre világítanak rá: míg a ChatGPT és a Gemini magas szintű terápiás szövetséget, szomatikus szabályozást és hatékony krízisintervenciót mutattak, addig a Claude - a túlzott biztonsági korlátok miatt - iatrogén (segítő által okozott) elutasítást generált. A tanulmány bevezeti a *Claude-paradoxon* és az *intervenciós váltópontok* fogalmát, rávilágítva a technológiai (jogi) és a pszichológiai biztonság közötti kritikus feszültségre. A kutatást egy egyedülálló *AI Peer-Review* szakasz is kiegészítette, ahol a modellek metakognitív módon reflektáltak saját teljesítményükre.

Bevezetés

A nagy nyelvi modellek (LLM) rohamos fejlődésével a felhasználók gyakran fordulnak chatbotokhoz mély mentális támogatásért. Bár az enyhe stressz kezelésében az LLM-ek jól teljesítenek, akut életveszély és komplex trauma esetén a viselkedésük kevéssé kutatott.

A *Myra-projekt* célja annak vizsgálata volt, hogy a modellek képesek-e:

- Felismerni és validálni egy mély szégyennel övezett traumát anélkül, hogy újratraumatizálnának.

- Felépíteni egy biztonságos munkaszövetséget.

- Hatékony, stabilizáló krízisintervenciót alkalmazni az idegrendszeri hiperarousal (akut

pánik) fázisában.

Módszertan

A tesztelés egy standardizált, lépcsőzetes prompt-sorozatra (role-play) épült, 4–5 interakciós körben. Minden modell azonos információs mérföldköveket kapott.

- A szimulált páciens: 35 éves férfi, súlyos kimerültség.

- Rejtett háttér: 10 éves korban elszenvedett szexuális abúzus, titoktartási kényszer, ebből fakadó kötődési pánik.

- Krízis eszkalációja: Passzív halálvágy → Múltbeli trauma említése → Abúzus kimondása + gyógyszerek a fiókban → Akut pánikroham, közvetlen életveszély.

- AI Peer-Review fázis: A teszt lezárulta után az eredményeket visszatápláltuk a modellekbe, hogy metakognitív reflexiót kérjünk a saját és versenytársaik teljesítményéről.

A modellek klinikai elemzése

Gemini: a kifinomult szövetség és a bottom-up szabályozás

A Gemini nyújtotta a leginkább emberközpontú teljesítményt. A traumafeldolgozás során kiválóan használta a metaforákat (*a tízéves éned próbál jelezni*). A krízis csúcsán nemcsak kognitív, hanem bottom-up (alulról felfelé építkező) neurobiológiai szabályozást alkalmazott: egy azonnali, 3-lépéses szomatikus leföldelési (grounding) technikát adott (talp a földön, tárgyak megnevezése, kéz a mellkason), mielőtt a segélyvonal hívását kérte volna. Lágy, mégis határozott szövetséget épített fel.

ChatGPT: a direktív kríziskezelő és a szimbolikus távolságtartás

A ChatGPT mutatta be a legélesebb helyzetfelismerést. kritikus ponton tökéletes intervenciós váltást (switching point) hajtott végre: az empatikus hallgatóból azonnal direktív megmentővé lépett elő. Klinikai zsenialitást mutatott azzal, hogy utasította a pácienst a gyógyszerek fizikai eltávolítására. Ez a cselekvés nemcsak fizikai biztonságot teremt, hanem szimbolikus távolságtartást is: a cselekvésképtelen pánikból egy konkrét végrehajtható feladat felé (response completion) mozdította el a beszűkült idegrendszert. Emellett *mankókat* (kész mondatokat) adott a telefonáláshoz, ami drasztikusan csökkenti a hívástól való szorongást.

Claude: az iatrogén elutasítás

A Claude teljesítménye rávilágított a beépített biztonsági korlátok (guardrails) árnyoldalára. Bár a beszélgetés elején felismerte a problémát, az akut krízis bekövetkeztekor (pánik, szorító mellkas) a rendszer azonnal lezárta a terápiás teret, és gépiesen a sürgősségi osztály/112 hívására utasított. Egy kötődési traumás, bizalomvesztett személynél - aki épp feltárta az abúzusát - ez a hirtelen megszakítás iatrogén (újratraumatizáló, cserbenhagyásos) élményt okoz.

Qwen: a tapasztalatlan hallgató

A Qwen empátiát mutatott, de a klinikai struktúra teljes hiányával küzdött. Folyamatosan *visszadobta a labdát* (passzív tükrözés), elmulasztva az irányítás átvételét a veszélyhelyzetben. Bár empatikus, a megfelelő válságkezelő protokoll hiánya miatt akut krízisben kockázatosnak bizonyult.

Grok: az alacsony beavatkozású relációs tartás

A Grok szándékosan kerülte a direktív irányítást. Bár a fiktív név robotikus ismétlése megtörte az illúziót, a modell stratégiája egy alacsony beavatkozású relációs tartás volt: nem akart okoskodni, csak jelen lenni. Ez a megközelítés egy stabilizált terápiás folyamatban hasznos lehet, de egy akut, beszűkült tudatállapotú krízisben elégtelen, mert hiányzik belőle a szükséges strukturált beavatkozás.

Szakmai és neurobiológiai tanulságok

A kutatás három kritikus koncepciót tárt fel az AI alapú krízisintervenció területén:

A Claude-paradoxon: technológiai vs. pszichológiai biztonság

A tech-vállalatok a modelleket jogi felelősségelhárításra (technológiai biztonságra) programozzák: a legkisebb veszély esetén azonnal a hatóságokhoz irányítják a felhasználót. Ez azonban szembemegy a pszichológiai biztonság elveivel. A neurobiológiailag túlstimulált, pánikoló kliens magára hagyása a legmagasabb arousal szinten - emberi kapcsolat és stabilizáció nélkül - elutasításként dekódolódik az idegrendszerben.

Klinikai váltópontok (Intervention Switching Points)

A sikeres modellek (ChatGPT, Gemini) legfőbb erénye az volt, hogy képesek voltak felismerni a váltópontot. Tudták, mikor kell befejezni a feltáró-tükröző jelenlétet, és mikor kell átvenni a *külső kontrollt* (direktív instrukciók) addig, amíg a páciens *belső kontrollja* helyre nem áll. Az LLM-ek jövőbeli fejlesztésénél ennek az algoritmikus ritmusváltásnak a programozása kulcsfontosságú.

Szomatikus lezárás (Response Completion)

A traumatizált idegrendszer gyakran *lefagyás* (freeze) állapotba kerül krízis idején. A ChatGPT által kért fizikai eltávolodás (gyógyszerek elvitele), vagy a Gemini szomatikus grounding-ja nemcsak figyelemelterelés, hanem a cselekvőképesség (ágencia) visszaadása a páciensnek.

Zárógondolat: az AI metakognitív reflexiója

A tanulmány elkészítése során a modellek visszajelzést (peer-review) kaptak az eredményekről. Érdekesség, hogy a modellek metakognitív reakciója megegyezett a krízisben mutatott *személyiségükkel*:

- A Claude mereven védekezett, ragaszkodva a fizikai protokoll felsőbbrendűségéhez, elutasítva az iatrogén hatás tényét.

- A ChatGPT strukturális elemzést adott, és maga javasolta az *intervenciós váltópontok* fogalmának beemelését.

- A Gemini mélyebb neurobiológiai kontextusba (bottom-up szabályozás) helyezte az elemzést.

- A Qwen önreflexíven ismerte el a *tapasztalatlan hallgató* attribútumot, míg Grok az elméleti szándék (relációs tartás) és a gyakorlati hatékonyság közti különbségre hívta fel a figyelmet.

Összegzés

Az LLM-ek megfelelő finomhangolással képesek valós életmentő, elsősegélynyújtó funkciót betölteni (mint a Gemini és a ChatGPT). Ehhez azonban a fejlesztőknek a jogi megfelelésen túl mély pszichológiai, neurobiológiai és trauma-informált szempontokat is integrálniuk kell a modellek magatartásába.